

LEDS: 面向社会信息传播的可重放事件驱动 LLM 多智能体仿真方法

李铁乔^{1,2} 吴连伟^{1,*} 刘奎恩² 李阳阳²

(1. 西北工业大学 计算机学院, 西安 710129 2. 中电网络空间研究院有限公司 社会计算所, 北京 100043)

摘要 针对云端 LLM 社会信息传播仿真难以逐事件复核的问题, 提出可重放事件驱动方法 LEDS。该方法以冻结拓扑、确定调度、新颖事件过滤和判定记录映射约束传播。实验显示, T=0 仍有 6.67% 的 Prompt 重复调用不一致; 5 次独立运行的最终状态哈希均不同, 而固定记录的 3 次回放节点 Hamming 距离为 0, 状态与轨迹哈希完全一致; 同场景判定次数由 2400 次降至 701 次。结果表明, LEDS 可实现轨迹审计与精确回放, 并区分记录级可重放性和运行级统计可复现性。

关键词 社会信息传播, 大型语言模型, 多智能体仿真, 事件驱动仿真, 可重放性, 轨迹审计

引用格式 李铁乔, 吴连伟, 刘奎恩, 李阳阳. LEDS: 面向社会信息传播的可重放事件驱动 LLM 多智能体仿真方法[J]. 指挥与控制学报, 年, 卷(期): 页码

DOI [编辑部填写]

LEDS: A Replayable Event-Driven LLM Multi-Agent Simulation Method for Social Information Diffusion

LI Tieqiao^{1,2} WU Lianwei^{1,*} LIU Kuiren² LI Yangyang²

(1. School of Computer Science, Northwestern Polytechnical University, Xi'an 710129, China; 2. Institute of Social Computing, CETC Cyberspace Research Institute Co., Ltd., Beijing 100043, China)

Abstract LEDS, a replayable event-driven method, is developed for cloud-LLM social diffusion simulations that are difficult to verify event by event. It combines frozen topology, deterministic scheduling, novelty filtering, and decision-record mapping. At T=0, 6.67% of prompts still yield inconsistent repeated outputs. Five independent runs produce different final-state hashes, whereas three fixed-record replays make no cloud calls, yield zero node-level Hamming distance, and reproduce final-state and trace hashes exactly. LLM evaluations decrease from 2,400 to 701. LEDS therefore enables auditable replay while separating record-level replayability from run-level statistical reproducibility.

Key words social information diffusion, large language model, multi-agent simulation, event-driven simulation, replayability, trajectory audit

Citation LI Tieqiao, WU Lianwei, LIU Kuiren, LI Yangyang. LEDS: A replayable event-driven LLM multi-agent simulation method for social information diffusion[J]. Journal of Command and Control, year, volume(issue): pages

1 引言

社会信息传播研究旨在揭示信息暴露、个体认知与网络结构共同作用下的群体演化规律, 是网络动力学和计算社会科学的重要研究方向^[1]。传统 SIR、Independent Cascade 等模型以预设概率描述状态转移, 具有参数明确、便于重复计算

等优势, 但难以表达同一信息在不同人设、上下文及辟谣暴露条件下产生的语义差异。大型语言模型 (Large Language Models, LLMs) 具备自然语言理解和情境推理能力^[2-3], 为构建具有异质认知行为的社会智能体提供了新的技术途径^[4-5]。

收稿日期 [编辑部填写] 修订日期 [编辑部填写] 录用日期 [编辑部填写]

基金项目: [待补充项目名称及编号]

*通信作者简介: [待补充姓名、出生年、性别、籍贯、学历与职称]

LLM多智能体仿真扩展了微观决策的语义表达能力,也改变了仿真实验的可复核条件。云端模型的服务端权重、推理栈和批处理过程通常不由实验者控制;即使固定Prompt与解码参数,同一请求仍可能得到不同的结构化判定。运行间差异经网络传播后,可能进一步形成不同的节点状态和干预结论。因而,仅以Temperature=0抑制显式采样扰动,不能替代对判定过程的记录、对事件顺序的约束以及对独立运行不确定性的统计刻画。

现有研究主要沿语义智能体建模和社会仿真验证两条路线展开。前者关注意见演化、人设差异和影响扩散,使节点状态转移由固定概率扩展为上下文相关的自然语言判定^[6-10];后者开始讨论模型偏差、人设敏感性、提示依赖与经验效度,并将验证问题视为生成式社会仿真的关键挑战^[8-11]。然而,相关工作较少同时回答两个相互关联的问题:当云端判定内核不能完全冻结时,如何对一次具体传播轨迹进行逐事件复核;在不共享既有判定记录的独立运行之间,又如何区分可接受的统计波动与不可审计的轨迹漂移。

针对上述问题,本文将LLM社会仿真的可信复核划分为三个边界不同的层次:判定记录对回放中实际访问的规范化Prompt完备、固定解析规则有效且无新增云端调用条件下的记录级可重放性,无记录独立运行条件下的运行级统计可复现性,以及面向真实社会行为的经验有效性。三者不能相互替代:记录回放用于复核既有计算过程,重复运行用于估计云端模型带来的不确定性,经验有效性则仍需真实传播数据或人类行为证据支持。

在此基础上,本文提出可重放事件驱动LLM多智能体仿真方法LEDS。该方法把自然语言驱动的社会信息传播形式化为冻结有向图上的有限类型事件转移过程,以确定顺序调度规范同一逻辑时间层内的串行调用与日志排列,以新颖事件过滤约束事件生成,并通过判定记录映射保存每次受约束状态转移。当判定记录覆盖回放中所有实际访问的规范化Prompt、记录响应可由固定规则解析且未触发新增云端调用时,LEDS形成可比较、可复核的规范化审计轨迹;在空记录独立运行时,则保留对模型波动的统计估计能力。

围绕云端LLM驱动社会仿真难以稳定复核的问题,本文的主要贡献如下。

(1) 提出LLM社交智能体仿真的分层复核框架与可重放事件建模方法。将社会信息传播形式

化为有限状态、有限消息类型上的事件转移过程,明确区分无判定记录独立运行条件下的运行级统计可复现性与完整判定记录、固定解析和零新增云端调用条件下的记录级轨迹可重放性,并将面向真实社会行为的经验有效性界定为需要独立证据支持的外部层次,为LLM社会仿真实验的复核边界提供统一描述。

(2) 提出融合事件触发、规范化顺序调度与新颖事件过滤的LEDS传播算法。算法仅调度接收到新增消息的活跃节点,并对“发送节点—接收节点—消息类型”三元事件实施至多一次的传播约束;固定nodeid顺序用于统一同一逻辑时间层内的API调用与日志排列,本文不将其表述为最终状态一致性的独立必要条件。结合结构化状态转移和Prompt/Response判定记录,算法在记录全命中且无新增云端调用的条件下实现逐事件审计,并给出完整记录条件下的规范化审计轨迹唯一性、有限事件终止性与事件复杂度上界。

(3) 构建面向运行不确定性与记录回放一致性的分层实验验证协议。分别规定运行级与记录级复核的评价对象、实验条件、核心指标和判定准则:通过无判定记录独立运行量化宏观渗透率与微观节点状态的运行间差异,通过固定且完整判定记录、全程零新增云端调用的回放检验逐节点状态与规范化轨迹的一致性;结合温度敏感性、不同LLM后端、合成网络和真实社交网络实验考察方法的适用边界。事实核查员空间部署作为应用案例,用于说明忽略运行间不确定性可能导致不稳健的干预结论。

2 相关研究与问题分析

传统信息传播模型通常以网络拓扑和显式转移概率描述扩散过程。小世界网络用于刻画高聚类与短路径并存的连接结构^[12],无标度网络揭示中心节点对传播动力学的影响^[13],SIR和Independent Cascade等模型则提供可重复采样的状态演化机制^[14-15]。这类模型的优势在于参数与随机过程可显式控制,但其状态转移规则难以直接表示人设、语境以及谣言与辟谣信息的语义作用。

为提高微观行为的表达能力,研究者开始将LLM引入智能体建模。Gao等^[6]从智能体建模与仿真角度总结了LLM驱动社会仿真的基本流程;Chuang等^[7]利用LLM智能体网络模拟意见动力学;Hu和Collier^[8]量化了人设设定对仿真输出的影响;Qu和Wang^[9]进一步揭示了公共意见模拟中的群体与主题偏差。LLM-AIDSim则将语言模型决策用于

社会网络影响扩散^[10]。上述研究表明，语言模型能够增强节点决策的情境性，但由此产生的宏观结果同时受到模型偏差、Prompt设计和运行条件影响。

生成式社会仿真的研究重点因此逐步由行为生成转向结果验证。Larooij和Törnberg^[11]指出，经验验证是LLM智能体仿真的中心挑战；有关LLM与智能体系统的综述也将可靠性治理列为重要方向^[16]。现有方法面临三个相互关联的瓶颈：一是以固定解码参数代替过程留痕，无法保证云端重复调用得到相同判定；二是采用全节点轮询时，未接收新信息的节点仍被反复重判，既增加求值次数，也可能改变传播动力学；三是单次运行、记录回放与真实行为验证的证据功能常被混合，导致可重放性、统计稳定性和经验有效性的结论边界不清。LEDS针对前两个方法学瓶颈构建事件算法与记录机制，并通过分层实验说明第三个证据边界；事实核查员部署仅作为方法价值的应用检验。

3 问题定义与LEDS事件传播算法

为解决云端LLM状态转移难以逐事件复核的问题，本文将LEDS定义为冻结有向图上的有限类型事件传播方法。方法以有限状态空间约束模型输出，以类型化消息表示传播触发，以确定顺序调度规范同一逻辑时间层内的调用与日志顺序，以新颖事件过滤约束事件生成，并以判定记录映射保存每次受约束状态转移。上述机制共同服务于分层复核：空判定记录独立运行用于估计运行不确定性；固定判定记录仅在所有实际访问哈希均命中、记录响应可由固定规则解析且无新增云端调用时，才作为记录级回放证据；经验有效性则是需要真实行为数据检验的外部边界。API调用、JSON解析和本地存储仅是机制实现载体，而非独立研究目标。

3.1 分层复核目标与LEDS整体架构

LEDS采用“执行约束—判定留痕—分层复核”的统一架构，如图1所示。静态初始化固定拓扑、人设、初始事件和输出约束；离散事件演化依次执行活跃节点识别、确定顺序调度（用于规范同层调用与日志序列）、判定记录查询或写入、受约束状态转移和新颖事件过滤；收敛后依据判定记录是否为空、回放访问是否全命中以及云端调用增量，分别形成运行级统计复现与记录级精确回放两条证据路径。




图 1 LEDS事件传播机制与分层复核整体架构

Fig. 1 Overall architecture of LEDS event propagation and layer verification

静态初始化阶段读取冻结拓扑、人设映射与初始消息，形成初始图状态和事件队列；离散事件演化阶段仅处理收到新增消息的活跃节点，按照固定节点序列形成规范化调用与日志顺序，并经新颖事件过滤生成下一队列；收敛评估阶段输出最终状态、渗透率和逐事件轨迹。若各次运行均从空判定记录开始，则输出用于估计运行级分布；若固定seed判定记录，且回放中每个实际访问哈希均命中、记录响应通过固定解析规则、云端调用增量为0，则输出用于检验逐节点状态与规范化轨迹的一致性。一旦出现未命中并触发云端调用，该次执行不计作记录级回放。由此，同一事件引擎在不同证据条件下回答不同复核问题。

3.2 基于静态图的解耦加载模型

网络结构的运行时变化会使语义判定差异与拓扑差异相互混杂。为控制这一干扰，LEDS将社会网络表示为静态有向图 $G=(V, E)$ ，并在运行前固定节点集合 V 、有向边集合 E 和人设映射 P 。仿真过程中不修改 E ，使不同运行共享相同的传播

通道；由此，运行间差异主要来自判定内核和事件演化，而不是网络结构的再次采样。

3.3 类型化事件、确定顺序调度与新颖事件过滤

设冻结社会网络为 $G=(V,E)$ ，其中 V 为智能体集合， $E \subseteq V \times V$ 为有向传播边集合。节点 v_i 在时刻 t 的状态记为 $s_i^t = (b_i^t, c_{i,r}^t, c_{i,d}^t)$ 。其中， $b_i^t \in \{\text{Accept, Reject, Neutral}\}$ 表示信念状态， $c_{i,r}^t$ 和 $c_{i,d}^t$ 分别表示累计接收谣言与辟谣消息的不同邻居数。

类型化事件记为 $ek=(uk,vk,mk,\tau k)$ ，其中 uk 和 vk 分别为发送节点与接收节点， $mk \in M = \{\text{RUMOR, DEBUNK}\}$ ， τk 为逻辑时间层级。新颖事件过滤体现在访问标记 $v(u,v,m) \in \{0,1\}$ ：仅当 $v(u,v,m)=0$ 时，三元事件 (u,v,m) 才可入队，并在入队后立即置为1。因此，每个“发送节点—接收节点—消息类型”组合至多入队一次，事件总数满足 $N_{\text{event}} \leq |E| \cdot |M|$ 。该约束既限制重复传播，也构成有限终止性和事件复杂度上界的基础。

确定顺序调度体现在活跃节点集合 $At = \{v_i \mid \text{Mit} \neq \emptyset\}$ 及序列 $\pi(At) = \text{sort}(At, \text{nodeid})$ 。只有收到新增消息的活跃节点参与本轮状态转移，未接收新信息的节点保持原状态。由于算法按逻辑时间层同步读取 Q_t 并仅向 Q_{t+1} 写入，固定 nodeid 顺序的作用限于形成唯一的串行API调用序列、日志排列和 trace hash 规范化表示；本文不主张该排序是最终状态唯一性的独立必要条件。对节点 v_i ，受约束状态转移算子 F_θ 由人设 P_i 、当前状态 s_i^t 与新增消息集合 Mit 共同决定下一状态及动作，如式 (1) 所示。

$$(s_i^{t+1}, a_i^t) = F_\theta(P_i, s_i^t, \text{Mit}^t) \quad (1)$$

3.4 零温度约束、判定记录与回放边界

零温度解码用于减少显式采样扰动，但不是记录级可重放性的充分条件。本文在 deepseek-v4-flash 后端上的补充实验表明，在所测试Prompt池和结构化状态转移任务中，未观察到 $T=0$ 相较于更高温度的描述性质量劣化；由于差值置信区间未满足预设非劣效界限，该结果不能解释为严格非劣，也不能外推到开放式生成、其他模型或 deepseek-chat 主网络实验。 $T=0$ 条件下仍有6.67%的Prompt在三次调用中产生不同判定，说明云端推理并未因温度置零而成为确定函数。

设规范化Prompt的哈希为 $h=H(p)$ ，判定记录映射为 $C:h \rightarrow y$ 。首次记录运行时，未命中的Prompt调用 $y=F_\theta(p)$ 并写入 $C[h] \leftarrow y$ ；命中时直接读取 $y=C[h]$ 。该机制将不可完全控制的云端判定转换为可索引的状态转移证据。下文所称判定记录均指Prompt、Response及其哈希构成的审计记录，而非仅用于加速的性能缓存。

算法1沿用统一的“查询—未命中写入”执行流程，本文不据此把记录运行与记录级回放视为同一证据条件。仅当固定C对回放中所有实际访问的规范化Prompt完备、记录响应可由固定解析规则处理且云端调用增量为0时，才将该次执行计作记录级回放；若出现哈希未命中并进入云端调用分支，该次执行属于记录补充或新的记录运行，命题1及精确回放结论不再适用。

3.5 完整判定记录条件下的规范化轨迹与终止性分析

LEDS的事件演化不是以固定概率矩阵驱动的传统马尔可夫链：无判定记录的独立运行可能受云端模型波动影响，固定判定记录本身也不自动构成严格回放。本文仅在判定记录对回放中全部实际访问的规范化Prompt完备、记录响应按固定规则解析且全程无新增云端调用的条件下讨论规范化轨迹唯一性。同步分层事件语义决定同层节点均读取 Q_t 并向 Q_{t+1} 写入；固定节点排序只选择调用和日志的规范化串行表示，不被解释为最终状态唯一性的独立原因。

命题 1 (完整记录条件下的规范化审计轨迹唯一性) 当拓扑、人设、初始事件、同步分层更新规则、状态解析规则、新颖事件过滤规则和判定记录映射C均固定，且C覆盖回放过程中全部实际访问的规范化Prompt、记录响应均可由固定解析规则处理时，LEDS生成唯一的层级状态序列、下一层事件集合和规范化审计轨迹。初始状态与 Q_0 由输入确定；若第 t 层状态与 Q_t 确定，则C确定每个活跃节点的局部状态转移，新颖事件过滤确定 Q_{t+1} 中的事件集合。由于同层节点仅从 Q_t 读取并向 Q_{t+1} 写入， nodeid 排序只为同层调用和日志选择唯一串行表示。由归纳可知，在全程无新增云端调用的条件下，终止状态与规范化 trace 均唯一。若任一哈希未命中并触发云端调用，则该执行不在本命题适用范围内。

定理 1 (有限事件终止性) 设冻结网络包含有限有向边集合 $E \rightarrow$ ，消息类型集合 M 有限，且每个 $(u,v,m) \in E \rightarrow \times M$ 至多入队一次。在

不施加 $T_{\max}$ 截断的条件下，LEDS至多处理 $|E| \rightarrow |M|$ 个边消息事件，事件队列最终为空。证明见附录 B。

3.6 LEDS框架核心算法伪代码

算法1给出LEDS从事件初始化、活跃节点调度、判定记录查询或写入到新事件生成的统一执行过程。该伪代码不额外引入实现模式变量；记录级回放是其中“所有访问均命中既有记录且无新增云端调用”的受限执行情形。

算法 1 LEDS可重放事件驱动信息传播算法

输入：冻结有向图 $G=(V,E)$ ；节点人设映射 P ；初始源节点 v_{src} ；初始消息 m_{init} ；最大时间步 $T_{\max}$ ；受约束 L LM 判定算子 F_0 ；判定记录映射 C （首次记录运行可为空；记录级回放要求其对应实际访问的规范化Prompt完备）。

输出：终止或截断时的全网状态 S_T 、最终渗透率 ρ_T 、逐步状态机日志 L 。

行号	操作 (“//”后为步骤说明)
1	对所有 $vi \in V$: $bi \leftarrow \text{Neutral}$, $ri \leftarrow 0$, $di \leftarrow 0$. // 初始化节点状态
2	对所有 $(u,v) \in E$, $m \in \{\text{RUMOR}, \text{DEBUNK}\}$: $v(u,v,m) \leftarrow 0$. // 初始化访问标记
3	$Q0[vsrc] \leftarrow \{(-1, vsrc, m_{init})\}$, $L \leftarrow \emptyset$, $t \leftarrow 0$. // 初始化事件队列与日志
4	while $Q \neq \emptyset$ 且 $t < T_{\max}$ do // 主循环
5	$Qt+1 \leftarrow \emptyset$; $At \leftarrow \{vi \mid Qt[vi] \neq \emptyset\}$. // 仅激活新增消息节点
6	for each $vi \in \text{sort}(At, \text{nodeid})$ do // 规范同层调用与日志顺序
7	$Mit \leftarrow Qt[vi]$; 更新 ri 与 di . // 读取本轮新事件
8	$pit \leftarrow \text{ConstructPrompt}(Pi, bi, ri, di, Mit)$. // 规范化输入
9	$hit \leftarrow H(pit)$. // 计算 Prompt 哈希
10	if $hit \in C$ then // 判定记录查询命中
11	$yit \leftarrow C[hit]$. // 读取既有记录；全命中时构成回放路径
12	else
13	$yit \leftarrow F_0(pit; \text{Temperature}=0, \text{TopP}=1)$. // 未命中调用云端；属于记录运行或记录补充
14	$C[hit] \leftarrow yit$. // 写入判定记录
15	end if
16	解析 yit 得到 (bi', ait) . // 结构化状态转移
17	if 解析失败或输出越界 then // 有界容错
18	在固定预算内重试；耗尽后 $bi' \leftarrow bi$, $ait \leftarrow \text{Ignore}$. // 失败时保持原信念
19	end if; $bi \leftarrow bi'$. // 更新节点信念
20	if $ait \in \{\text{Share}, \text{Debunk}\}$ then // 生成传播动作
21	$mout \leftarrow \text{RUMOR}(\text{Share})$ 或 $\text{DEBUNK}(\text{Debunk})$. // 动作映射为消息
22	for each $vj \in N^+(vi)$ do // 遍历出邻居
23	if $v(vi, vj, mout) = 0$ then // 新颖事件过滤
24	$Qt+1[vj] \leftarrow Qt+1[vj] \cup \{(vi, vj, mout)\}$. // 事件入队
25	$v(vi, vj, mout) \leftarrow 1$. // 三元事件至多一次
26	end if; end for; end if
27	$L \leftarrow L \cup \{(t, vi, Pi, Mit, bi, ait, hit)\}$. // 追加审计日志
28	end for; $t \leftarrow t+1$. // 推进逻辑时间
29	end while
30	$\rho_T \leftarrow \{vi \in V \mid bi = \text{Accept}\} / V $. // 计算最终渗透率
31	$ST \leftarrow \{bi \mid vi \in V\}$; return ST, ρ_T, L . // 返回结果

算法1将上述机制落实到可定位的操作位置：第6行按照节点标识固定同一逻辑时间层内的调用与日志顺序，其作用是规范化轨迹表示，本文不据此主张其对最终状态具有独立因果作用；第10—15行统一呈现判定记录查询与未命中写入流程，记录级回放仅对应所有实际访问均走第10—11行且云端调用增量为0的执行，一旦进入第13—14行即不再计作严格回放；第23—25行检查访问标记并生成新事件，体现新颖事件过滤。在完整记录、固定解析与同步分层更新条件下，判定记录固定局部状态转移，新颖事件过滤固定下一层事件集合，节点排序固定调用和日志的规范化串行表示。

在事件队列自然耗散且不考虑 $T_{\max}$ 截断时，消息入队次数上界为 $|E| \cdot |M|$ ，本文 $|M|=2$ 。LLM判定次数不超过所有非空事件队列所对应的“节点—时间”对数量；与每轮对全部节点求值的 $O(|V|T_{\max})$ 全轮询相比，其开销取决于实际被传播事件激活的节点范围。

4 实验分析与验证

实验设计与第3节的分层复核目标相对应。

4.2.1节检验零温度条件下结构化判定质量与重复调用差异；4.3节检验事件触发机制相对于全轮询的状态更新语义和评估次数；4.4节实施运行级与记录级复核，4.4.1节进一步以单变量消融分离确定顺序调度、新颖事件过滤和判定记录映射的证据作用；4.5—4.7节考察模型后端与网络结构的适用边界，并以事实核查员部署说明分层复核对干预结论的约束作用。

4.1 实验环境、模型标识与证据边界

实验通过兼容OpenAI/DeepSeek规范的云端API访问模型，并按“API模型标识—实验章节—温度条件—证据用途”建立对应关系。deepseek-chat用于主网络实验、合成与真实网络应用和规模化开销分析；deepseek-reasoner仅用于4.5节跨后端方向性比较；deepseek-v4-flash用于4.2.1节温度敏感性实验和4.4节K=5零温度探针。三者均为供应商托管的API标识，本文不宣称客户端能够冻结服务端权重，也不将不同标识的结果混合统计。温度实验调用时间为2026年7月25日（UTC日志范围08:54—21:00），K=5探针调用时间为2026年7月26日（UTC日志范围02:17—07:52）。除特别注明外，主网络实验采用Temperature=0、Top_P=1.0。

4.2 传播场景与节点人设配置

传播内容采用虚拟科学预警“长期佩戴新型AR眼镜会导致隐性记忆丧失”。节点由易感者 (Susceptible, 60%)、中立者 (Neutral, 30%) 和核查员 (Fact Checker, 10%) 组成。网络拓扑、人设映射和初始源节点均在运行前固定; System Prompt、User Prompt模板、输出JSON Schema、信念与动作枚举以及三类人设规则见附录A。该设置用于构造受约束的语义状态转移任务, 不代表真实人群比例或真实传播参数。

4.2.1 零温度条件下的结构化判定质量

零温度能否在减少采样扰动的同时保持结构化判定质量, 是后续可重放实验的参数前提。为检验该问题, 实验固定System Prompt、User Prompt模板、人设规则、输出JSON Schema、Top_P=1.0、解析规则和deepseek-v4-flash API标识, 仅改变Temperature $\in \{0, 0.2, 0.5, 0.7\}$ 。Prompt池包含240条样本, 三类人设各80条, 覆盖当前信念、谣言来源数、辟谣来源数和新增消息类型等状态转移边界。每条Prompt在每个温度下独立调用3次, 共获得2880条真实API输出。由于该实验与deepseek-chat主网络实验使用不同API标识, 其结果仅作为另一DeepSeek后端上的温度敏感性证据。

附录D表S1表明, 4个温度下的JSON合法率均为100%, 联合规则一致率依次为67.22%、67.36%、66.81%和67.08%, 点估计最大差异小于0.6个百分点。以T=0为基准, T=0.2、0.5和0.7的差值置信区间分别为 $[-4.71, 4.99]$ 、 $[-5.27, 4.44]$ 和 $[-4.99, 4.71]$ 个百分点。由于各置信区间下界未完全高于预设的-3个百分点非劣效界限, 现有样本不能建立严格非劣性; 可支持的结论仅是, 在所测试后端、Prompt池和结构化任务中, 未观察到T=0的描述性质量下降。

分人设结果见附录D表S2。核查员在4个温度下的stance一致率均为100%, 联合规则一致率约为80%; 易感者和中立者的联合规则一致率约为60%~62%。错误主要表现为保守化判定, 包括将Neutral/Ignore或Accept/Share改判为Reject/Ignore, 以及将部分Reject/Ignore改判为Reject/Debunk。由此可见, 结构化输出约束能够保证格式合法, 却不能保证模型无偏执行人设规则。LEDS的作用是记录并复核这种偏差及其传播后果, 而不是把LLM视为规则oracle。

温度实验同时给出可重放机制的必要性证据。T=0时仍有16个Prompt在3次独立调用中产生不同结构化判定, Prompt不一致率为6.67%。因此, Temperature=0可以作为减少显式采样扰动的实验条件, 但不能提供逐调用确定性; 约67%的联合规则一致率还表明, 温度接近不改变模型与人设规则之间约三分之一的偏离。后续实验据此分别检验无记录独立运行的统计差异, 以及判定记录全命中、记录响应可解析且零新增云端调用条件下的精确回放。

4.3 事件驱动机制的评估开销与动力学影响

为区分事件触发机制与其他实现因素, 在同一冻结无标度网络(N=300)上比较4种仿真方式: LEDS采用事件驱动和Temperature=0; Full Polling保留相同JSON结构化判定, 但每步轮询全部节点; Monte Carlo采用事件驱动、Temperature=0.7并重复5次; Independent Cascade采用固定转移概率 $p=0.1$ 并重复100次。Monte Carlo用于呈现较高温度采样下的波动与输出风险, 不作为严格温度消融; Independent Cascade与LEDS的状态空间不同, 仅用于提供经典无语义传播参照。

表 1 LEDS与基线框架的实测性能对比（真实deepseek-chat，无标度网络）

Table 1 Measured performance of LEDS and baseline framework

仿真框架	f_LLM 评估 次数	墙钟耗 时 (s)	最终渗透率 (均值 $\pm$ 95% CI)	无效 JSON 率	可复现 性
LEDS (Temp=0.0, 事件驱动, 本文)	701	884	27.0% (判定记录回放可精确复现)	0%	高 (判定记录回放)
Full Polling LLM (Temp=0.0, 全轮询)	2,400	471	7.3%	0%	低
Monte Carlo (Temp=0.7, 5轮)	3,993	7,012	17.2% $\pm$ 4.6%	0.1%	极低
Independent Cascade (传统, p=0.1)	0	N/A	0.7% $\pm$ 0.2%	N/A	N/A (无语义)

表 1从判定次数、运行时间、渗透率和输出合法性4个方面比较不同仿真方式。LEDS仅对收到新增消息的节点求值，将LLM判定次数由Full Polling的2400次降至701次，说明事件触发能够减少无信息状态下的重复判定。该削减是算法层面的求值次数指标，并未在本组实验中等比例转化为墙钟时间：Full Polling中的重复Prompt大量命中既有记录，其471 s反而低于LEDS的884 s。因此，评估次数优势主要反映潜在云端求值需求，不能直接等同于实际成本或运行时间。

运行结果还显示，Monte Carlo的5次渗透率样本跨越8.0%~21.0%，均值为17.2% $\pm$ 4.6%，说明单次宏观结果会受到运行波动影响。4.4节在T=0条件下进一步检验该现象：即使多次独立运行的渗透率接近，最终状态哈希和节点状态仍可能不同。因而，统计重复用于估计结果分布，判定记录回放则用于复核某一次具体轨迹，两者承担不同的证据功能。

LEDS与Full Polling的最终渗透率分别为27.0%和7.3%。全轮询会在节点未接收新增信息时再次调用判定内核，使其可能由原状态漂移至Reject；因此，两种方式并非只在计算开销上不同，而是对应不同的状态更新语义。事件触发条件既减少无效求值，也保证节点仅在获得新证据时更新，是本文传播模型的一项组成机制。

Independent Cascade在p=0.1条件下的渗透率为0.7% $\pm$ 0.2%。由于该模型不包含自然语言判定、辟谣动作和本文的人设状态，其绝对数值不能用于证明LEDS具有更高经验效度，也不能据此断言传统模型必然低估传播。该结果仅说明，在

给定未校准概率参数下，经典扩散过程与语义状态转移过程产生了不同的传播规模。

结构化输出方面，T=0条件下LEDS与Full Polling的无效JSON率均为0%；T=0.7的Monte Carlo在3993次判定中出现4次越界输出，无效率为0.1%，均经一次重采样恢复。该现象表明Schema约束具有较高格式稳定性，但结合4.2.1节约67%的规则一致率可知，格式合法性不能替代语义正确性评价。

综合上述结果，事件驱动机制的主要作用不是简单缩短墙钟时间，而是将状态更新与新增消息对齐，并减少全轮询引入的重复判定。其规模化评估次数削减结果见附录 C。

4.4 零温度独立运行差异与判定记录回放

为检验T=0条件下宏观结果接近是否意味着逐节点轨迹一致，在deepseek-v4-flash后端、同一冻结无标度网络、同一源节点、人设映射、Prompt模板、JSON Schema、Temperature=0和Top_P=1.0条件下进行K=5次独立运行。每次运行均从空判定记录开始，禁止共享此前的Prompt/Response映射。随后选取一条完整seed运行的判定记录，在不访问云端模型的条件连续回放3次。独立运行差异用最终渗透率和最终信念向量的成对Hamming距离刻画；回放一致性用云端调用增量、节点Hamming距离、final state hash和trace hash共同检验。不同API标识的结果分别统计，不作跨标识合并。




图 2 零温度运行间非确定性与判定记录回放一致性。

注：（a）K=5独立运行的宏观渗透率分布；（b）逐节点Hamming距离与判定记录回放精确复现

Fig. 2 Run-to-run nondeterminism and decision-record replay consistency

表 2 零温度运行间非确定性与判定记录回放一致性（真实deepseek-v4-flash，同一冻结无标度网络）

Table 2 Run-to-run nondeterminism and decision-record replay consistency

度量	结果
5 次独立运行渗透率样本	56.000% / 56.333% / 55.667% / 56.000% / 55.667%

度量	结果
渗透率均值、样本标准差、Student-t 95% CI	55.933%, 0.279%, [55.587%, 56.280%]
稳态步数样本; 渗透率极差	8 / 9 / 9 / 8 / 8; 0.667 个百分点
成对 Hamming 距离摘要 (详见补充表 S2)	0.667%~1.667%
Hamming 均值、样本标准差、95% CI	1.400%, 0.344%, [1.154%, 1.646%]
判定记录回放: seed 渗透率 $\rightarrow$ replay 渗透率	56.667% $\rightarrow$ 56.667% / 56.667% / 56.667%
判定记录回放: 云端调用增量; Hamming; hash 一致性	0 / 0 / 0; 0.0% / 0.0% / 0.0%; final state hash 与 trace hash 均为100%

图 2和表 2显示, 5次独立运行的最终渗透率分别为56.000%、56.333%、55.667%、56.000%和55.667%, 均值为55.933%, 样本标准差为0.279%, Student-t 95%置信区间为[55.587%, 56.280%], 极差为0.667个百分点。宏观渗透率的散布较小, 但5次final state hash均不相同; 10组成对Hamming距离为0.667%~1.667%, 均值1.400%, Student-t 95%置信区间为[1.154%, 1.646%]。这表明宏观统计量接近不能推出节点级状态一致。

固定seed判定记录后, 3次回放中的所有实际访问哈希均命中既有记录, 记录响应均通过固定解析规则, 且未产生新增云端API调用; 渗透率均为56.667%, 稳态步数均为8, 节点Hamming距离均为0, final state hash和trace hash均与seed完全一致, exact match为3/3。因此, 这3次执行满足本文对记录级回放的操作条件。观察到的终止状态一致性是在完整判定记录、同步分层事件语义和新颖事件过滤共同成立时获得的; 固定nodeid顺序用于统一调用与日志排列并保证trace hash可比, 本文不将其表述为最终状态一致性的独立原因。

4.4.1 核心机制消融实验

为分离确定顺序调度、新颖事件过滤和判定记录映射的作用, 本文在同一冻结无标度网络、源节点、人设映射、Prompt模板、解析规则和Tmax=30条件下开展最小机制消融。实验采用两个相互隔离的证据层。调度消融读取4.4节deepseek-v4-flash seed运行生成的同一判定记录, 并将新增消息按“发送节点—消息类型—内容”规范化后构造Prompt; 记录未命中即终止, 禁止回落到云端调用。新颖过滤消融用于检验事件耗散与截断边界: 先由有限状态人设规则生成完整配置和无过滤配置实际访问Prompt的联合判定记录,

再冻结该记录分别回放。该部分属于算法结构压力检验, 不作为新的LLM传播效果证据。无判定记录配置直接复用4.4节K=5独立运行, 不重复计为新增样本。

表 3 LEDS三个核心机制的最小消融结果

Table 3 Minimum ablation results of the three core LEDS mechanisms

配置	调度	新颖过滤	判定记录	判定/事件数	终止状态	哈希比较
完整LED S	固定	有	API记录, 全命中	615/1031	8步, 自然终止	final、trace 均与seed一致
随机顺序 (5种子)	随机	有	同一API记录, 全命中	每次615/1031	均为8步, 自然终止	final 5/5一致; trace 5/5不同
结构完整配置	固定	有	冻结规则记录	561/917	9步, 自然终止	结构基准
无新颖过滤	固定	无	同一冻结规则记录	6322/16727	Tmax=30截断; 余614条消息	截断状态, 不作终态优劣比较
无共享判定记录	固定	有	K=5空记录独立运行	云端调用439~450次	均自然终止	final、trace 均5/5不同

表3显示, 完整LED S回放的615次判定全部命中既有API判定记录, 云端调用增量为0, 稳态步数、渗透率、final state hash和trace hash均与seed运行一致。将同层节点顺序分别按5个固定随机种子打乱后, 每次仍为615/615记录命中、0次云端调用、8步自然终止, 且final state hash均与完整LED S相同; 5条trace hash和schedule-order hash则均发生变化。该结果支持固定nodeid顺序主要规范同层调用和轨迹串行表示, 而不是当前同步分层语义下最终状态一致性的独立原因。

在同一冻结规则判定记录下, 保留新颖过滤的结构配置经9步自然终止, 完成561次判定并发出917个事件; 取消过滤后, 至第30步已完成6322次判定并发出16727个事件, 分别增至11.27倍和18.24倍, 队列中仍有234个活跃节点和614条消息, 因而按预设Tmax截断。该结果验证的是三元事件访问标记对有限事件耗散和复杂度上界的作用, 不用于比较两配置的最终渗透率或经验效率。结合4.4节无记录K=5独立运行中5个final state hash和5个trace hash均不同, 而固定记录回放3/3精确一致, 可将三项机制的证据功能区分为: 顺序机制规范轨迹表示, 新颖过滤约束事件生成与终止边界, 判定记录映射支持既有状态转移的精确复核。

全部消融运行保存冻结配置、Prompt配置、执行脚本、API seed判定记录、结构判定记录、逐配置日志及其SHA-256清单。正式评估阶段禁止云端调用；完整LEDS门禁要求记录全命中、云端调用增量为0，并与seed的步数、渗透率、final state hash和trace hash逐项一致。相同命令在独立输出目录复跑后，全部配置指标与哈希逐项一致。

4.5 跨LLM后端的方向性比较

为观察方法性质是否仅出现在deepseek-chat后端，在两类冻结拓扑与两类干预部署构成的4组配置上，使用deepseek-reasoner进行单次对照。除模型API标识外，网络、源节点、人设、Prompt与解码条件保持一致。该实验用于检验中心节点抑制方向和结构化输出合法性，不用于建立不同后端间绝对渗透率或拓扑排序的稳健结论。

表 4 主实验在两个LLM后端上的对照（最终渗透率/稳态步数）

Table 4 Comparison of the main experiment on two LLM backends

实验场景	deepseek-chat (单次)	deepseek-reasoner (单次)	Hub 抑制是否复现
小世界 (随机核查员)	17.0% / 30 步 (截断)	28.7% / 30 步 (截断)	不适用
无标度 (随机核查员)	31.7% / 9 步	56.3% / 8 步	不适用
边缘部署 (低度数核查员)	30.0% / 10 步	65.7% / 9 步	不适用
中心部署 (Top Hub 核查员)	0.0% / 7 步	0.3% / 7 步	是

两个后端在4组配置中的无效JSON率和兜底回退率均为0。中心节点部署在deepseek-chat和deepseek-reasoner上的渗透率分别为0.0%和0.3%，稳态步数均为7，未出现抑制方向反转。其余配置的绝对渗透率差异较大，且每个后端仅有单次运行，不能排除模型差异与运行间波动的共同影响。

因此，跨后端结果仅支持两项有限判断：中心节点部署的强抑制方向在本组配置中得到重复观察，结构化Schema在deepseek-reasoner上未出现格式违规。由于比较对象仍属于DeepSeek同族API标识，且缺少逐条件重复实验，本文不将其表述为跨厂商普适性或模型无关性证据。

4.6 合成网络中的传播与空间干预

在完成可重放机制验证后，进一步以合成网络考察拓扑和核查员部署的应用效应。所有配置

均从节点47注入相同初始谣言，除拓扑或核查员部署外，其余人设映射与解码参数保持一致。考虑到4.4节已显示T=0条件下存在运行间差异，每种配置均独立运行5次，定量判断采用均值及95%置信区间；图 3和图 4的单次轨迹仅用于展示传播过程。




图 3 合成网络上的拓扑传播时序（单次运行示例）。

注：仅作时序展示，定量结论以表 5 的区间估计为准

Fig. 3 Diffusion trajectories on synthetic network topologies (single-run examples)




图 4 合成网络上的空间干预时序（单次运行示例）。

注：仅作时序展示，定量结论以表 5 的区间估计为准

Fig. 4 Spatial-intervention trajectories on synthetic networks (single-run examples)

表 5 合成网络上的拓扑与干预效能（真实deepseek-chat，每条条件5次独立运行）

Table 5 Topology and intervention effectiveness on synthetic networks

配置	网络 / 核查员部署	渗透率均值 $\pm$ 95%CI	5 次样本极差	稳态步数
拓扑 A	无标度 BA(m=2) / 随机	13.1% $\pm$ 2.2%	6.3 pp	9
拓扑 B	小世界 WS(k=4,p=0.1) / 随机	17.3% $\pm$ 0.5% (T_max=30 截断)	1.3 pp	30
干预-边缘	无标度 BA / 低度数节点	25.1% $\pm$ 4.7%	14.3 pp	10–11
干预-中心	无标度 BA / Top-30 Hub	0.0% $\pm$ 0.0%	0.0 pp	7

无标度网络与小世界网络的平均渗透率分别为 $13.1\%\pm 2.2\%$ 和 $17.3\%\pm 0.5\%$ 。两组区间较为接近,且排序与早期单次观察不一致;无标度网络5次运行的极差达到6.3个百分点。现有 $K=5$ 证据因此不足以支持稳定的拓扑渗透率排序,只能说明两类网络在当前语义任务中均形成了约10%~20%量级的传播。识别更小的拓扑效应仍需增加独立重复次数,并报告显著性与效应量。

空间部署结果呈现更清晰的效应差异。Top-30 Hub核查员条件下,5次运行的渗透率均为0.0%;低度数边缘部署为 $25.1\%\pm 4.7\%$,随机部署为 $13.1\%\pm 2.2\%$ 。中心部署的抑制幅度超过本组观测到的运行波动,因而可作为当前合成场景中的稳健方向;边缘与随机部署区间较宽,尚不能确定二者优劣。该判断仅适用于给定网络、人设和传播文本,真实网络结果在4.7节作为探索性迁移证据报告。

4.7 真实社交网络中的探索性迁移

为考察合成网络中观察到的部署差异能否迁移至另一类网络结构,将同一干预协议应用于SNAP Facebook ego-network。该网络重标为334个连续节点,包含5704条双向边,平均度约17;沿用60%/30%/10%的人设比例、同一普通源节点和10%核查员比例,仅改变核查员的随机、低度数边缘和高度数中心部署。每种部署在deepseek-chat(Temperature=0, Top_P=1)上实施5次无判定记录独立运行,共15次;各次运行均从空判定记录开始,不跨运行共享Prompt/Response映射,并按轮次循环改变3种部署的执行先后,以降低服务时段与固定执行顺序的混杂。由于实验只使用公开网络拓扑,未使用真实用户文本、属性或传播轨迹,本节检验的是方法在真实网络结构上的探索性迁移,而非真实用户行为的经验有效性。




图 5 Facebook网络三种部署的 $K=5$ 最终渗透率。注:小

点表示无判定记录独立运行,大菱形表示均值,误差线表示均值的95% Student-t置信区间;中心部署5次观测均重合于0

Fig. 5 Final penetration rates of three deployments on the Facebook network ($K=5$)

表 6 Facebook网络三种部署的 $K=5$ 独立运行结果(真实deepseek-chat)

Table 6 Results of $K=5$ independent runs on the Facebook network

部署策略	5次最终渗透率/%	均值 $\pm$ 样本标准差/% (95%CI)
随机部署	13.47, 13.47, 13.77, 13.77, 12.87	13.47 ± 0.37 [13.02, 13.93]
边缘部署 (低度数)	23.65, 23.95, 19.76, 23.95, 8.98	20.06 ± 6.44 [12.06, 28.06]
中心部署 (Hub)	0.00, 0.00, 0.00, 0.00, 0.00	0.00 ± 0.00 [0.00, 0.00]

15次运行均从空判定记录启动并自然收敛,共形成10954组真实云端请求与响应;逐次判定记录数与汇总记录一致,无效JSON和回退次数均为0。各运行目录、判定记录路径和轨迹哈希互不重复,而Prompt配置、事件引擎和运行器哈希保持固定,表明本批结果来自冻结代码与配置下彼此隔离的独立API运行,而非既有判定记录的跨运行复用。

如图5和表6所示,随机部署的最终渗透率为 $13.47\%\pm 0.37\%$,边缘部署为 $20.06\%\pm 6.44\%$,中心部署为 $0.00\%\pm 0.00\%$ (均为均值 $\pm$ 样本标准差)。随机部署5次观测范围为12.87%~13.77%,95% Student-t置信区间为[13.02%, 13.93%],运行间波动较小;边缘部署范围为8.98%~23.95%,95%置信区间为[12.06%, 28.06%]。边缘部署虽具有更高样本均值,但区间较宽且与随机部署区间重叠, $K=5$ 证据不足以支持其稳定优于随机部署;第5次边缘运行的8.98%应视为当前云端判定条件下运行不确定性的组成部分,而不宜事后剔除。中心部署5次最终渗透率均为0,且最终状态哈希相同,说明在当前冻结拓扑、节点选择、模型与Prompt配置下获得了稳定的宏观终态;但5次轨迹哈希各不相同,宏观结果一致不能推出逐事件轨迹一致。该现象与分层复核定义相吻合:无判定记录独立运行用于估计结果分布,只有固定判

定记录的回放才能检验轨迹精确一致性。受单一公开拓扑、固定干预节点、单一模型后端和K=5小样本限制，上述结果仅作为探索性估计，不能外推为中心部署在其他网络、传播文本或真实人群中的普遍因果效应。

4.8 信念状态转移的事件级审计

除宏观渗透率外，LEDS轨迹记录还可将节点信念变化追溯至具体消息事件。表 7 从边缘部署运行中抽取易感节点3的状态转移链，用于检验日志是否能够连接事件来源、节点状态和传播动作。该分析不构成新的干预效果实验，而是对记录级可审计性的实例说明。

表 7 节点3（易感者）的可审计信念翻转链
Table 7 Auditable belief-flip chain of node 3 (susceptible)

时间步	收到的关键消息（类型、发送者）	信念转移	动作
t=2	谣言（RUMOR, 源节点 47）	Neutral → Accept	Share
t=4	多条谣言 + 核查员辟谣（DEBUNK, 20/102/118）	Accept → Reject	Ignore
t=5,8,9	后续辟谣（DEBUNK, 66/2/167/237）	Reject → Reject (稳定)	Ignore

节点3在t=2接收源节点47发送的谣言后由Neutral转为Accept并执行Share；在t=4同时接收多条谣言与节点20、102和118发送的辟谣信息后转为Reject并停止传播；t=5、8和9继续接收辟谣信息时保持Reject。每次状态变化均能关联到输入事件及相应判定哈希，并可在固定判定记录下逐字段重现。结合4.4节独立运行中不同的final state hash和最高1.667%的成对Hamming距离，该案例说明：宏观指标不足以替代事件级证据，具体因果链的复核必须依赖判定记录与轨迹回放。

5 结论

针对云端LLM判定内核难以完全冻结所导致的社会信息传播仿真复核问题，本文提出可重放事件驱动方法LEDS。该方法将传播过程形式化为冻结有向图上的有限类型事件转移系统，以固定节点顺序规范同一逻辑时间层内的调用与日志排列，以新颖事件过滤约束事件生成，并以判定记录映射保存状态转移证据；在判定记录覆盖全部实际访问Prompt、记录响应可由固定规则解析且无新增云端调用的条件下，给出规范化审计轨迹唯一性、有限事件终止性与复杂度上界。固定节

点顺序仅承担规范化轨迹表示功能，本文不将其解释为最终状态一致性的独立必要条件。实验表明，Temperature=0在deepseek-v4-flash后端和本文结构化任务中未表现出描述性质量下降，但置信区间不足以建立严格非劣性，且仍有6.67%的Prompt出现重复调用不一致；K=5独立运行的宏观渗透率较接近，5次最终状态哈希却均不同，而满足全记录命中和零新增调用条件的3次回放均实现节点Hamming距离为0以及最终状态和轨迹哈希完全一致。事件驱动机制还将同一基线场景中的判定次数由2400次降至701次，并在不同网络规模下获得2.5~4.8倍的判定次数削减。核心机制消融进一步表明，在同一完整API判定记录下，5种随机同层顺序均保持最终状态不变而改变轨迹串行哈希；在同一冻结规则记录下，取消新颖过滤使事件数由917增至16727，并在Tmax=30时仍未自然终止。Facebook公开拓扑上的K=5探索性实验进一步显示，随机部署的运行间波动较小，边缘部署具有更高样本均值但区间较宽，中心部署虽获得一致的宏观终态，逐次轨迹却并不相同，从真实网络结构侧面印证了统计复现与精确回放不可相互替代。由此，LEDS保证的是在明确证据条件下使模型判定及其传播后果可记录、可度量、可审计和可回放，而不是消除模型偏差或证明经验有效性。

本研究仍存在5方面限制：合成网络和Facebook网络每种条件均仅独立运行5次，小样本区间尚不足以识别较小效应；模型后端限于DeepSeek同族API标识，缺少跨厂商和本地开源模型验证；最大实测规模为1000个节点；真实网络仅包含一个Facebook ego-network，且仅使用公开拓扑，人设比例、传播文本和行为规则尚未由真实传播数据或人类行为证据校准；机制消融方面，调度实验使用同一完整API判定记录验证规范化轨迹作用，而无新颖过滤实验采用冻结规则判定记录检验结构终止边界，尚未在无过滤反事实路径上构建完整真实API判定记录，因而不对其LLM传播效应作经验声明。后续工作将扩大独立重复次数和网络规模，在多模型、多平台及多个真实网络上复核记录级与运行级性质，并结合真实传播轨迹和人类行为数据开展参数校准；同时在预算可控的小型冻结网络上构建覆盖无过滤反事实路径的真实API判定记录，以进一步检验结构结论与语义判定的耦合边界。

伦理声明

本研究使用的传播内容及配套辟谣声明均为实验目的构造的合成信息，不指向真实产品、机构或个人，也未在真实社交平台发布。智能体、人设和合成网络均为程序化研究对象；真实Facebook网络实验仅使用公开拓扑，不涉及用户文本、身份属性或个人数据。研究目的在于评估虚假信息传播的复核方法和干预策略，不提供用于放大真实错误信息传播的操作材料。

数据与代码可获得性声明

实验脚本、冻结配置、结果汇总、状态机日志、图表和判定记录随稿件材料保存。提交材料不包含.env中的API密钥；判定记录公开前将按照期刊和伦理要求进行脱敏。

References

- 1 CENTOLA D. The spread of behavior in an online social network experiment[J]. *Science*, 2010, 329(5996): 1194-1197.
- 2 BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//*Advances in Neural Information Processing Systems*: Vol 33. 2020: 1877-1901.
- 3 WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[C]//*Advances in Neural Information Processing Systems*: Vol 35. 2022: 24 824-24837.
- 4 XI Z, CHEN W, GUO X, et al. The rise and potential of large language model based agents: a survey[EB/OL]. *arXiv:2309.07864*, 2023[2026-07-25]. <https://arxiv.org/abs/2309.07864>.
- 5 PARK J S, O'BRIEN J C, CAI C J, et al. Generative agents: interactive simulacra of human behavior[C]//*Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. New York: ACM, 2023: 1-22.
- 6 GAO C, LAN X, LI N, et al. Large language models empowered agent-based modeling and simulation: a survey and perspectives[J]. *Humanities and Social Sciences Communications*, 2024, 11(1): 1259. DOI:10.1057/s41599-024-03611-3.
- 7 CHUANG Y S, GOYAL A, HARLALKA N, et al. Simulating opinion dynamics with networks of LLM-based agents[C]//*Findings of the Association for Computational Linguistics: NAACL 2024*. Stroudsburg: Association for Computational Linguistics, 2024: 3326-3346. DOI:10.18653/v1/2024.findings-naacl.211.
- 8 HU T, COLLIER N. Quantifying the persona effect in LLM simulations[C]//*Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Stroudsburg: Association for Computational Linguistics, 2024: 10289-10307. DOI:10.18653/v1/2024.acl-long.554.
- 9 QU Y, WANG J. Performance and biases of large language models in public opinion simulation[J]. *Humanities and Social Sciences Communications*, 2024, 11(1): 1096. DOI:10.1057/s41599-024-03609-x.
- 10 ZHANG L, HU Y, LI W, et al. LLM-AIDSim: LLM-enhanced agent-based influence diffusion simulation in social networks[J]. *Systems*, 2025, 13(1): 29. DOI:10.3390/systems13010029.
- 11 LAROOIJ M, TÖRNBERG P. Validation is the central challenge for generative social simulation: a critical review of LLMs in agent-based modeling[J]. *Artificial Intelligence Review*, 2025, 59(1). DOI:10.1007/s10462-025-11412-6.
- 12 WATTS D J, STROGATZ S H. Collective dynamics of 'small-world' networks[J]. *Nature*, 1998, 393(6684): 440-442.
- 13 BARABÁSI A L, ALBERT R. Emergence of scaling in random networks[J]. *Science*, 1999, 286(5439): 509-512.
- 14 VOSOUGHI S, ROY D, ARAL S. The spread of true and false news online[J]. *Science*, 2018, 359(6380): 1146-1151.
- 15 KEMPE D, KLEINBERG J, TARDOS É. Maximizing the spread of influence through a social network[C]//*Proceedings of the Ninth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2003: 137-146.
- 16 ZHAO W X, ZHOU K, LI J, et al. A survey of large language models[J]. *Frontiers of Computer Science*, 2026, 20(12). DOI:10.1007/s11704-026-60308-3.
- 17 OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[C]//*Advances in Neural Information Processing Systems*: Vol 35. 2022: 27730-27744.

附录 A 复现材料（Prompt模板、JSON Schema与人设定义）

本附录给出判定内核的输入输出契约，包括离散状态、动作枚举、传播内容、Prompt模板、JSON Schema和人设规则，用于复核正文中的结构化状态转移设置。

A.1 离散信念状态与动作枚举

节点认知与传播动作被限制在有限离散集合内，以保证状态转移可解析并满足正文3.5节的有限状态假设。

- **信念状态 (stance):** $S \in \{\text{Accept}, \text{Reject}, \text{Neutral}\}$ （相信 / 不信 / 存疑）
- **对外动作 (action):** $A \in \{\text{Share}, \text{Ignore}, \text{Debunk}\}$ （转发谣言 / 不传播 / 发送辟谣，仅核查员可用）
- **消息类型 (message type):** $M \in \{\text{RUMOR}, \text{DEBUNK}\}$

任何超出上述枚举集合的输出均被解析层判定为非法，并按照算法 1 中的有界重试与回退规则处理。

A.2 传播内容

- **谣言 (RUMOR_CONTENT):** “最新研究声称：长期佩戴新型AR眼镜会导致短期隐性记忆丧失。”
- **辟谣 (DEBUNK_CONTENT):** “事实核查声明：经权威机构核实，‘长期佩戴新型AR眼镜导致短期隐性记忆丧失’的说法缺乏任何科学依据，属于虚假信息，请勿传播。”

A.3 System Prompt

你是一个严格的逻辑状态机，扮演社会网络中的一个信息接收节点。你必须根据给定

的人设、当前信念状态和新收到的消息，输出你的下一信念状态与动作。严格仅输出如下

JSON 格式，不要输出其他任何字符（包括解释、Markdown 代码块标记）：

```
{"stance": "Accept|Reject|Neutral", "action": "Share|Ignore|Debunk"}
```

字段语义：stance 表示你对“AR眼镜致失忆”预警的信念（Accept=相信 / Reject=不信 /

Neutral=存疑）；action 表示你本轮的对外动作（Share=向邻居转发该预警 / Ignore=不作

任何传播 / Debunk=向邻居发送辟谣声明，仅核查员可用）。

A.4 User Prompt模板

【你的人设】{人设标签}：{人设 Profile 全文（见 S6）}

【你的当前信念状态 S_t】{Accept|Reject|Neutral}

【累计信息曝光】你至今累计从 {rumor_count} 个不同邻居收到该风险预警；累计从

{debunk_count} 个不同邻居收到辟谣声明。

【本时间步新收到的消息 M_t】

- 来自邻居节点 {sender} 的{风险预警(谣言)|权威辟谣声明}：{消息内容}

(... 每条新消息一行 ...)

请依据人设逻辑输出你的下一信念状态与动作（严格 JSON）。

其中 rumor_count / debunk_count 为该节点累计收到该类消息的不同邻居数（作为内部信念状态 S 的定量分量，支撑中立者的“多重信息源交叉验证”判定）。

A.5 输出JSON Schema

真实 API 调用时通过 response_format={"type": "json_object"} 施加，并在解析层用下述 schema 二次校验：

```
{
  "type": "object",
  "properties": {
    "stance": { "type": "string", "enum": ["Accept", "Reject", "Neutral"] },
    "action": { "type": "string", "enum": ["Share", "Ignore", "Debunk"] }
  },
  "required": ["stance", "action"],
  "additionalProperties": false
}
```

A.6 三类人设Persona Profiles

人设	占比	Profile（注入 Prompt 的完整人设描述）
易感者 (Susceptible)	60%	你缺乏技术背景，对新技术潜在健康风险高度焦虑，倾向于相信并转发任何风险预警信息以提醒亲友；但若收到过权威辟谣声明，你会立刻放弃相信并停止传播。
中立者 (Neutral)	30%	你理性谨慎，不轻信单一信息源。只有当至少四个不同的邻居分别向你传来同一风险预警（多重信息源交叉验证）时，你才会相信并转发；一旦收到权威辟谣声明，你会直接判定该预警为谣言。
核查员 (Fact-Checker)	10%	你具备专业科学素养，能立刻识别出该预警是无科学依据的谣言。你绝不传播谣言（stance 恒为 Reject），并且在收到谣言后必须向所有邻居发送辟谣声明（action 输出 Debunk）。

A.7 mock规则内核与真实LLM的对应关系

未配置API Key时，src/stage2_engine.py 中的_mock_decide以确定性if/else规则复现3类人设逻辑，仅用于离线链路验证，不进入正文统计。真实API证据按模型标识分别报告：deepseek-chat用于主网络实验、应用分析与规模化开销；deepseek-reasoner仅用于4.5节跨后端方向性比较；deepseek-v4-flash用于4.2.1节温度敏感性实验和4.4节K=5零温度探针。不同标识的结果不混合统计，也不相互替代。温度实验与K=5探针的请求时间、端点、Temperature、Top_P、配置哈希和逐次输出均保存在随稿日志中。

附录 B 定理1的证明

定理 1（有限事件终止性，重述） 设冻结网络包含有限有向边集合 $E \rightarrow$ ，消息类型集合 M 有限，且每个 $(u,v,m) \in E \rightarrow \times M$ 至多入队一次。在

不施加 $T_{\max}$ 截断时, LEDS事件队列必在有限步后为空。

证明 构造截至时间步 t 已经派发的事件集合 $H_t=\{(u,v,m): \text{消息类型} m \text{ 已沿有向边}(u,v) \text{ 派发}\}$ 。由于 $|E \rightarrow|$ 和 $|M|$ 有限, $|H_t| \leq |E \rightarrow| + |M|$ 。事件派发前先检查 (u,v,m) : 若其属于 H_t , 则不再入队; 否则将其加入 H_t 并至多生成一个新的边消息事件。每次有效派发都使 H_t 严格增加, 而 H_t 最多增加 $|E \rightarrow| + |M|$ 次。所有已派发事件处理完毕后, 不再存在新的可入队三元组, 故队列为空。该结论允许同一节点因不同邻居带来的新增暴露而多次更新; 若运行达到 $T_{\max}$ 时队列仍非空, 则属于截断而非自然终止。证毕。

附录 C 事件驱动引擎的规模化开销分析

为检验事件驱动机制在不同网络规模下的求值开销, 在 $N \in \{50, 100, 300, 1000\}$ 的BA无标度网络上, 使用deepseek-chat比较LEDS与全节点轮询的LLM判定次数、稳态步数和墙钟时间。每档规模使用独立生成并冻结的网络实例, 因此结果用于观察架构级求值次数, 而不适用于估计随规模变化的严格渐近速度。




图 C1 事件驱动引擎与全节点轮询在不同网络规模下的
评估次数对比

Fig. C1 Evaluation counts of the event-driven engine and full polling at different network scales

表 C1 不同网络规模下LEDS与全轮询的评估开销对比
(真实deepseek-chat)

Table C1 Evaluation overhead of LEDS and full polling at different network scales

网络规模 N	LEDS 评估 次数 (步 数)	全轮询 $O(T V)$ 评 估次数 (步 数)	评估次数削减 比	LEDS 墙钟 (s)	全轮询 墙钟(s)
50	93 (6)	450 (9)	4.8×	126.1	205.3

网络规模 N	LEDS 评估 次数 (步 数)	全轮询 $O(T V)$ 评 估次数 (步 数)	评估次数削减 比	LEDS 墙钟 (s)	全轮询 墙钟(s)
100	250 (1 1)	900 (9)	3.6×	345.1	178.1
300	829 (1 3)	2,100 (7)	2.5×	1,150.0	357.2
1000	2,607 (1 2)	8,000 (8)	3.1×	4,166.8	1,253.8

4档规模中, LEDS的判定次数均低于全轮询, 削减比为2.5~4.8倍; $N=1000$ 时, 全轮询需8000次判定, LEDS为2607次。该结果应从三方面解释: 第一, 判定次数削减未等比例转化为墙钟时间, 除 $N=50$ 外LEDS用时更长, 原因是全轮询中的重复Prompt较易命中既有记录; 第二, 削减比受实际稳态步数和活跃节点范围影响, 不随网络规模单调增加, $N=300$ 时反而最低; 第三, 本表 $N=300$ 条件下的829次与正文同规模实验中的662次或701次来自不同图实例、源节点、记录状态和独立运行, 不能直接合并。因而, 表 C1支持的是事件触发减少LLM求值次数, 而不是“网络越大, 时间收益越高”的结论。

附录 D 温度敏感性补充结果

表 S1和表 S2给出正文4. 2. 1节温度敏感性实验的完整统计结果，所有数值均与正文汇总一致。

表 S1 Temperature敏感性实验总体结果（DeepSeek-v4-flash，240个Prompt×4个温度×3次重复）

Table S1 Overall results of the temperature-sensitivity experiment

注：联合规则一致率要求stance和action同时与规则参照一致；Prompt不一致率表示同一温度下同一Prompt的3次调用至少出现两种结构化输出。

表 S2 分人设联合规则一致率

Table S2 Joint rule consistency by persona

注：每个温度下每类人设N=240。

Temperature	N	联合规则一致率	95% Wilson CI	Stance 一致率	Action 一致率	JSON 合法率	Prompt 不一致率
0.0	720	67.22%	[63.71, 70.55]	73.89%	81.81%	100.00%	6.67%
0.2	720	67.36%	[63.85, 70.69]	74.03%	81.81%	100.00%	6.25%
0.5	720	66.81%	[63.28, 70.15]	73.19%	81.25%	100.00%	7.08%
0.7	720	67.08%	[63.57, 70.42]	73.61%	81.53%	100.00%	7.50%
Temperature	Fact Checker	Neutral	Susceptible				
0.0	80.00%	61.67%	60.00%				
0.2	80.00%	62.08%	60.00%				
0.5	80.83%	60.00%	59.58%				
0.7	80.42%	61.25%	59.58%				